

Sanidade Vegetal AI

Monitoramento Inteligente e Diagnostico Fitossanitario em Cana-de-Acucar

SPRINT REVIEW 1 - Ingestao, Amostragem e Exploracao de Dados (Fases Sample e Explore - SEMMA)

Sprint 1 do Grupo | FATEC Rio Claro 2026

DATA DE ENTREGA	PROFESSOR / AVALIADOR	EQUIPE
03/09/2026	Julio Cesar de Lemos	Sanidade Vegetal - Grupo 1

1. Identificacao da Equipe e Matriz RACI / Accountability

Nome	Papel	Destaque / Responsabilidade Tecnica (Accountable)
Heitor Vitti Partezani	Dev Team	Dicionario de Dados (38 vars, md/csv), DER conceitual (6 entidades) e amostragem estratificada (IR=11.67).
Guilherme Peres Romanzotti	Dev Team	Facilitacao agil, setup do GitHub Sanidade-Vegetal, blindagem do .gitignore (5,3 GB) e board Trello.
Cesar Augusto Oliveira Bovo	Dev Team	Definicao fitossanitaria (Ferrugem vs Saudavel), 5 hipoteses (H1-H5), padroes HSV/GLCM e Notebook Master.
Elisa Almeida Alcantara	Dev Team	Accountable (A) - Engenharia de Dados / Ingestao: Carga automatizada dos dados brutos (5.553 + 1.020 arqs).
Luis Otavio Routh da Silva	Dev Team	Accountable (A) - Relato Tecnico / Qualidade: Producao do Relato Vol. 1, Sprint Review e saneamento (.txt/Na).
Marvin Cristhian Gomes Pinto	Dev Team	Analise exploratoria univariada/bivariada das distribuicoes de variaveis, dimensoes e suporte a ABT.

(A) = Accountable: Membro com responsabilidade principal pela entrega tecnica da camada indicada.

2. Meta da Sprint Review 1

Esta cerimonia consolida o encerramento do primeiro ciclo do projeto, focado na ingestao massiva, garantia de integridade, amostragem e exploracao preliminar (Fases Sample e Explore do SEMMA) para diagnostico fitossanitario na cultura da Cana-de-Acucar (Saccharum spp.), com foco em Ferrugem (Puccinia spp.) e impacto severo em TCH (produtividade) e ATR (rendimento industrial).

Fluxo Metodologico Validado na Sprint 1: [ENTRADA] -> Ingestao de 6.573 arquivos brutos (5,3 GB) via Mendeley Data e Roboflow. [SEMMA 1] -> SAMPLE: Amostragem representativa + Saneamento (descarte de 2 arquivos .txt corrompidos). [SEMMA 2] -> EXPLORE: Validacao de 6.571 imagens RGB integras + Analise Univariada + Dicionario de Dados. [SAIDA] -> Base higienizada + Notebook central reprodutivel + Relato da Solucao Vol. 1 + ABT preliminar.

3. Arquitetura da Solucao e Pipeline de Dados

Camada	Tecnologia / Descrição	Responsavel	Status
Governanca & Repositorio	GitHub Sanidade-Vegetal com .gitignore configurado para 5,3 GB.	Guilherme Romanzotti	[OK]
Ingestao de Dados Brutos	Carga automatizada em datasets/mendeley_data e roboflow (5.553 + 1.020 arqs)	Elisa Alcantara (A)	[OK]
Saneamento & Filtro	Algoritmo de validacao de canais RGB (expurgo de 2 arquivos .txt sem canais).	Luis Otavio (A)	[OK]
Dicionario & Amostragem	Mapeamento de 38 campos, DER conceitual e particionamento (4.860 / 464 / 22)	Heitor Vitti	[OK]
Notebook Principal	Notebook unificado integrando ingestao, amostragem, EDA e geracao da ABT.	Cesar Bovo	[OK]
Documentacao Tecnica	Artefato formal Relato da Solucao Vol. 1 cobrindo fases Sample e Explore.	Luis Otavio (A)	[OK]

4. Itens Entregues - Sprint 1 do Grupo

#	Titulo / Descrição	Responsavel	Trello / Evidencia	Status
1	Configuracao do Ambiente e Repositorio (.gitignore 5,3 GB e Trello)	Guilherme Romanzotti	trello.com/c/env_setup	Concluido
2	Ingestao e Catalogacao de Dados Brutos (Roboflow + Mendeley)	Elisa Alcantara	trello.com/c/data_ingest	Concluido
3	Dicionario de Dados e Amostragem (DER conceitual e amostragem estruturada).	Heitor Vitti	trello.com/c/data_dict	Concluido
4	Definicao Fitossanitaria e Notebook Principal (5 hipoteses e pipeline)	Cesar Bovo	trello.com/c/notebook_core	Concluido
5	Exploracao Univariada das Variaveis (Frequencias, canais e resolucao)	Luca Cristhian	trello.com/c/eda_univariada	Concluido
6	Tratamento de Inconsistencias e Nulos (Expurgo dos 2 arquivos .txt)	Luis Otavio	trello.com/c/data_cleaning	Concluido
7	Producao do Relato da Solucao Vol. 1 (Documento formal SEMM)	Luis Otavio	trello.com/c/relato_vol1	Concluido

5. Definition of Done (DoD)

#	Critério de Conclusao	Status
1	Pipeline de carregamento e validacao de dados executando sem erros em ambiente local e Jupyter.	[OK] Validado
2	Codigo estruturado, comentado e commitado no repositorio GitHub Sanidade-Vegetal.	[OK] Validado
3	100% das 6.571 imagens confirmadas como validas no padrao tridimensional RGB (altura, largura, 3 canais).	[OK] Validado
4	Card movido para a coluna 'Concluido' no Trello com criterios de aceite 100% checados.	[OK] Validado
5	Artefato tecnico Relato da Solucao Vol. 1 redigido, revisado e aprovado pelo time.	[OK] Validado

6. Visao do Produto e Metricas do Dataset Consolidado

Dimensao / Patologia	Volume (Imagens)	Proporcao (%)	Status de Densidade
Particao de Treino (Train)	4.860 imagens	~87,5%	Conjunto de Ajuste
Particao de Validacao (Valid)	464 imagens	~8,4%	Conjunto de Calibracao
Particao de Teste (Test)	227 imagens	~4,1%	Conjunto Hold-Out
Escaldadura (Leaf Scald)	439 imagens	6,7%	Minoritaria Severa
Mosaico (Mosaic Virus)	1.257 imagens	19,1%	Majoritaria / Media
Enfezamento (Grassy Shoot)	206 imagens	3,1%	Minoritaria Severa
Ferrugem e Folhas Sadias	5.551 imagens	84,5%	Distribuicao no Split

7. Checklist de Governanca, QA e Etica nos Dados

Ref.	Item de Verificacao	Status	Evidencia
DS-01	Rastreabilidade de Fontes: Fontes catalogadas com links e licencas (Roboflow e Mendeley).	[OK] Validado	Relato Vol. 1 §2
DS-02	Protecao de Repositorio: Configuracao de .gitignore para bloquear 5,3 GB de dados brutos.	[OK] Validado	GitHub
DS-03	Saneamento sem Imputacao Espuria: Expurgo de 2 arquivos .txt sem imputar canais artificiais.	[OK] Validado	Notebook S1
DS-04	Prevencao de Data Leakage: Manutencao estrita das particoes isoladas desde a amostragem.	[OK] Validado	Relato Vol. 1 §3
DS-05	Reprodutibilidade: Notebook com importacoes fixadas e caminhos relativos estruturados.	[OK] Validado	Notebook S1

8. Dossie de Artefatos e 9. Matriz de Avaliacao

Criterio de Avaliacao	Peso	Evidencia de 'Pronto' (Definition of Done)
Qualidade do Relato da Solucao	3,5	Relato Vol. 1 completo com contextualizacao agronomica, fontes e justificativa SEMMA.
Exploracao e Integridade	3,0	6.571 imagens validadas em RGB, 2 expurgos (99,97% aproveitamento) e EDA documentada.
Accountability (RACI) e Governanca	2,0	Divisao transparente de papeis, Accountables definidos e gestao de debitos tecnicos.
Integracao e Reprodutibilidade	1,5	Repositorio estruturado, governanca de 5,3 GB no .gitignore e notebook executando 100%.
PONTUACAO TOTAL	10,0	Pontuacao maxima alcancada na Sprint Review 1.

10. Retrospectiva - Desafios, Licoes e Proximos Passos

[ALERTA] Problemas, Impedimentos e Comunicacao - O que nao funcionou:

- Volume Excessivo de Dados Locais: O download dos 5,3 GB exigiu adequacao emergencial do .gitignore para viabilizar commits no GitHub.
- Presenca de Arquivos Nao-Visuais: Identificados 2 arquivos .txt corrompidos sem canais de cor (modo_cor: NaN), descartados pontualmente por Luis.
- Debito Tecnico Planejado (Marvin): A analise multivariada avancada e a consolidacao final de features da ABT foram refinadas no Master Notebook e integradas no backlog da Sprint 2.

[OK] O que funcionou bem:

- Comunicacao e Alinhamento: Sincronia agil da equipe via Trello e reunioes de alinhamento com resolucao rapida de impedimentos.
- Aproveitamento Excepcional da Base: Alcance de 99,97% de aproveitamento util (6.571 imagens integras em RGB).
- Notebook Centralizado: Estruturacao liderada por Cesar garantiu execucao reproduzivel de ponta a ponta sem conflitos.

[NEXT] Conclusoes e Proximos Passos (Transicao para Sprint 2 - Fase MODIFY):

Com a amostragem e a exploracao concluidas, a equipe avanca diretamente para a Fase Modify na Sprint 2, atacando os 5 cartoes no Trello:

1. Diagnostico, Deteccao e Tratamento de Outliers Fotometricos: Tratamento de saturacao luminosa e sombras excessivas de campo via CLAHE.
2. Discretizacao de Variaveis Continuas (Binning Estatistico): Criacao de faixas estatisticas para variaveis continuas auxiliares.
3. Analise de Multicolinearidade e Selecao Preliminar de Atributos: Calculo de matrizes de correlacao de Pearson/Spearman e eliminacao de redundancias.
4. Construcão do Pipeline Atômico com ColumnTransformer (Anti-Leakage): Blindagem do fluxo de preprocessamento com StandardScaler no split train.
5. Atualizacao do Dicionario de Dados: Registro formal das novas features cromaticas (HSV, ExG, ExR) e texturais (GLCM Haralick).

