

Qualidade dos Dados

Análise Comparativa de Duas Bases

Sugarcane Disease Classification — Roboflow vs. Mendeley Data



Data de geração: 03 de setembro de 2026, 13:07

Bases analisadas: Base 1 (5.551 imagens · 5 classes) e Base 2 (1.020 arquivos · 3 classes)

Escopo da auditoria: Duplicatas · Tipagem · Valores ausentes · Domínio · Rótulos

SUMÁRIO EXECUTIVO

Este relatório audita e compara duas bases de imagens do mesmo domínio — classificação de doenças em cana-de-açúcar — em cinco dimensões de qualidade: duplicidade, consistência de tipos/formatos, valores ausentes, aderência ao domínio e coerência de rótulos.

A Base 1 (Roboflow Curado) obteve nota máxima, 10,0/10, sem nenhuma não conformidade em nenhum critério. A Base 2 (Mendeley Data) obteve 8,2/10: os quatro critérios estruturais permanecem perfeitos, mas a verificação de duplicatas revelou 109 arquivos duplicados por conteúdo (hash MD5) e 4 arquivos com sufixo "Copy/Cópia" no nome, reduzindo esse critério para 1/10.

As duas bases também diferem substancialmente em estrutura, tamanho e organização: a Base 1 já está pré-processada, dividida em splits (treino/teste/validação) e padronizada em 640×640 JPEG; a Base 2 é um conjunto bruto, organizado em pastas por classe, sem CSV, com resoluções e formatos de imagem heterogêneos (JPEG e MPO).



1. COMPARAÇÃO LADO A LADO

MÉTRICA	BASE 1 (ROBOFLOW)	BASE 2 (MENDELEY DATA)
Total de imagens/arquivos	5.551	1.020
Número de classes	5	3
Estrutura	CSV por split (train/test/valid)	Pastas por classe, sem CSV
Pré-processamento	Padronizado — 640×640 JPEG	Variado — 20 resoluções distintas
Duplicatas (hash MD5)	0	109
Duplicatas (todas as formas)	0	113
Imagens corrompidas	0	0
Resoluções distintas	1	20
Score geral	10,0 / 10	8,2 / 10

Pontuação geral — comparativo



2. DIFERENÇAS CRUCIAIS ENTRE AS BASES

- Tamanho: Base 1 tem 5.551 imagens contra 1.020 arquivos na Base 2 — a Base 1 é mais de 5× maior.

- **Classes:** Base 1 cobre 5 categorias (Healthy, Mosaic, RedRot, Rust, Yellow); Base 2 cobre apenas 3 (GRASSYSHOT, LEAF SCALD DISEASES, MOASIC) — as taxonomias não são diretamente compatíveis.
- **Estrutura:** Base 1 já vem dividida em splits com CSV de rótulos; Base 2 é apenas pastas por classe, exigindo split manual antes do treinamento.
- **Pré-processamento:** Base 1 é 100% padronizada (640×640, JPEG); Base 2 mistura 20 resoluções diferentes e dois formatos (JPEG e MPO), exigindo normalização antes do uso.

3. BASE 1 — ROBOFLOW CURADO

Estrutura em CSV por split, com imagens já padronizadas em 640×640 pixels, totalizando 5.551 imagens em 5 classes de doença.

DIVISÃO	IMAGENS	% DO TOTAL
Treino	4.860	87,6%
Teste	227	4,1%
Validação	464	8,4%
Total	5.551	100%

Distribuição de classes (total, todas as divisões)

Healthy		1146
Mosaic		882
RedRot		1268
Rust		1057
Yellow		1198

3.1 Pontuação por dimensão — Base 1

Duplicatas		10
Tipos inconsistentes		10
Missing values		10
Fora do domínio		10
Inconsistências de rótulo		10

3.2 Principais verificações

- ✓ Duplicatas por nome, registro completo e hash MD5: 0 em todos os métodos.
- ✓ Schema idêntico entre train/test/valid (mesmos tipos de coluna em todas as divisões).
- ✓ Nenhum valor ausente em nenhuma coluna, em nenhuma divisão.
- ✓ Nenhum rótulo fora do domínio {0,1} e nenhum registro multi-label.
- ✓ Nenhuma inconsistência entre prefixo do arquivo e rótulo no CSV.
- ✓ Todas as 5.551 imagens em 640×640, formato JPEG — sem exceções.

4. BASE 2 — IMAGENS BRUTAS ORIGINAIS

Conjunto bruto organizado em pastas por classe, sem CSV de rótulos, totalizando 1.020 arquivos distribuídos em 3 classes.

CLASSE (PASTA)	ARQUIVOS	% DO TOTAL
GRASSYSHOT	206	20,2%
LEAF SCALD DISEASES	439	43,0%
MOASIC	375	36,8%
Total	1.020	100%

Distribuição de arquivos por classe



4.1 Pontuação por dimensão — Base 2



4.2 Ponto crítico: duplicatas de conteúdo

A verificação por hash MD5 (comparação byte a byte do conteúdo da imagem, independente do nome do arquivo) identificou 109 arquivos duplicados agrupados em 50 grupos de conteúdo idêntico. Adicionalmente, 4 arquivos carregam o sufixo "Copy"/"Cópia" no nome, um indício adicional de duplicação manual durante a coleta.

INDICADOR DE DUPLICIDADE	VALOR
Duplicatas por nome (mesma classe)	0
Duplicatas por nome (entre classes)	0
Arquivos com sufixo 'Copy/Cópia'	4
Grupos de conteúdo idêntico (hash MD5)	50
Arquivos duplicados por hash MD5	109

Exemplos de grupos duplicados (hash MD5)

- ✗ DSC_4150.JPG e DSC_4150 - Copy.JPG (pasta GRASSYSHOT) — mesmo conteúdo binário.
- ✗ DSC_4209.JPG e DSC_4209 - Copy.JPG (pasta GRASSYSHOT) — mesmo conteúdo binário.
- ✗ 3 variações de "WhatsApp Image 2024-04-28 at 3.08.08 PM" (pasta GRASSYSHOT) — mesmo conteúdo, nomes de exportação diferentes.
- ✗ 3 variações de "WhatsApp Image 2024-04-28 at 3.25.19 PM" (pasta GRASSYSHOT) — mesmo conteúdo, nomes de exportação diferentes.
- ✓ Nenhuma imagem corrompida ou com erro de leitura: 0 ocorrências.

4.3 Heterogeneidade de formato e resolução

Diferente da Base 1, a Base 2 mistura dois formatos de imagem (JPEG e o formato multi-imagem MPO, comum em câmeras com modo 3D/duplo sensor) e apresenta 20 resoluções distintas, da menor (1008×968) à maior (6016×6005).

CLASSE	JPEG	MPO
GRASSYSHOT	69	137
LEAF SCALD DISEASES	61	378
MOASIC	178	197

- Resoluções distintas encontradas: 20 — a mais frequente é 6016×4016 (687 arquivos, câmera principal).
- Tamanho médio de arquivo: 5.125,6 KB · mediana: 6.719,5 KB · mínimo: 58,4 KB · máximo: 14.517,6 KB.
- ✓ Arquivos não-imagem encontrados: 0 — todos os 1.020 arquivos são imagens válidas.

4.4 Demais verificações

- ✓ Tipos/formatos: sem CSV, a checagem equivalente (extensão e formato de imagem) não encontrou arquivos inválidos.
- ✓ Missing values: não se aplica a estrutura de pastas; verificação equivalente (imagens corrompidas/extensões inválidas) = 0.
- ✓ Fora do domínio: as 3 classes correspondem exatamente aos nomes das 3 pastas, sem divergência.
- ✓ Inconsistências de rótulo (token do nome do arquivo vs. pasta de origem): 0.

5. CONCLUSÃO E RECOMENDAÇÕES

As duas bases têm papéis diferentes no ciclo de vida do projeto. A Base 1 está pronta para uso imediato em treinamento — estruturada, padronizada e sem nenhuma não conformidade. A Base 2 é uma fonte bruta valiosa (classes distintas, imagens de alta resolução), mas precisa de tratamento antes de ser incorporada a qualquer pipeline.

- ✓ Usar a Base 1 diretamente para treinamento e validação — nenhuma ação corretiva é necessária.
- ⚠ Antes de usar a Base 2, remover os 109 arquivos duplicados (50 grupos por hash MD5) e os 4 arquivos com sufixo 'Copy/Cópia', mantendo apenas uma cópia por conteúdo.
- ⚠ Padronizar a Base 2 para uma resolução e formato únicos (ex.: 640×640 JPEG) antes de combiná-la com a Base 1, convertendo os arquivos MPO para JPEG.
- ⚠ Definir de forma explícita o mapeamento entre as classes da Base 2 (GRASSYSHOT, LEAF SCALD DISEASES, MOASIC) e as da Base 1, já que as taxonomias não coincidem — MOASIC provavelmente corresponde a Mosaic, mas GRASSYSHOT e LEAF SCALD DISEASES não têm equivalente direto na Base 1.
- Após limpeza e padronização, gerar um CSV de splits (train/test/valid) para a Base 2, no mesmo formato da Base 1, para permitir combinação consistente entre as duas fontes.
- Repetir esta auditoria após cada etapa de tratamento da Base 2, para confirmar que as não conformidades foram eliminadas antes do treinamento.